

Parcours Data Scientist



Projet N°8 : Déployez un modèle dans le cloud

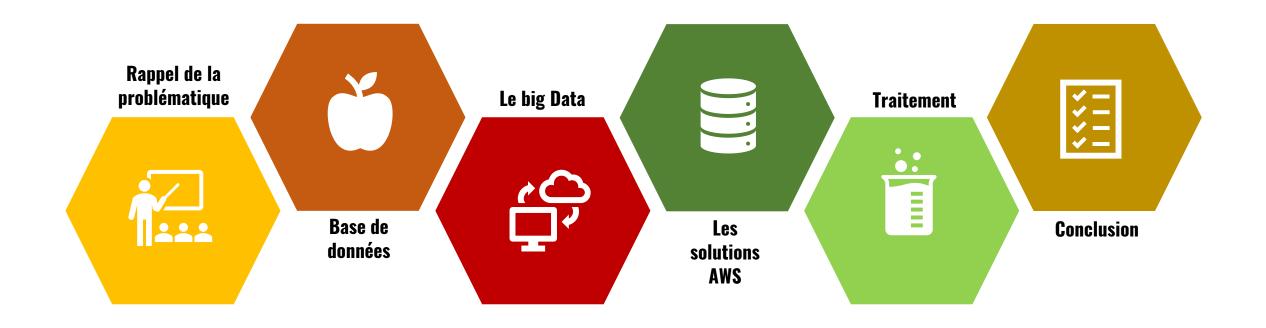




Daniel CHASTANET



Sommaire





Rappel de la problématique

« Fruits! », start-up de l'AgriTech

But à long terme :

Préserver la biodiversité des fruits par le traitement spécifique de chaque espèce via la cueillette par des robots cueilleurs intelligents.

1ere étape : se faire connaître :

Application mobile : Une photo d'un fruit \rightarrow des informations sur le fruit.

Objectifs de la mission :

- Mettre en place une première version du moteur de classification des images de fruits.
- Construire une première version de l'architecture Big Data nécessaire.





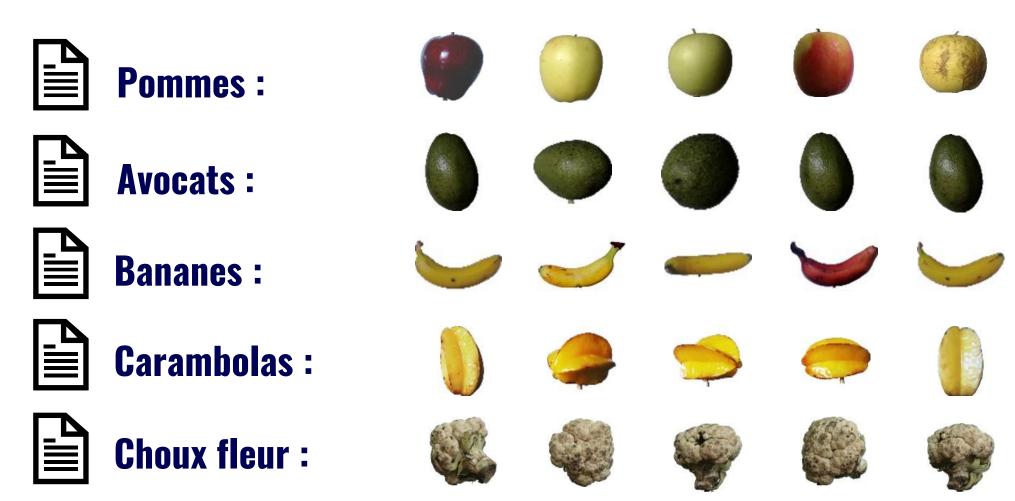
Partie I – Le jeu de données



Image : <u>facilogi.com</u>



Fruits 360
A dataset with 90380 images of 131 fruits and vegetables





Partie II – Le big DATA



Image: acualiteinformatique



Les données

1991 World Wide Web



2000 368 540 000 d'ordinateurs connectés FranceConnect

Nombre d'usagers

500 000 20 millions En 2017 En 2021 30 millions

France

- Ouverture de FranceConnect à Pôle emploi en mars 2021 et à la CAF en juillet 2021
 Lancement de FranceConnect à pour les démarches demandant un giveau de sécuri
- Lancement de FranceConnect+ pour les démarches demandant un niveau de sécurit plus élevé d'ici mai 2021
- Connexion aux identités numériques européennes à l'été 20

Plan de transformation numérique de l'état



Premier modem

1992 1 000 000 d'ordinateurs connectés



1999/2000

Internet of Things

Objets connectés

2021 4 600 000 000 d'ordinateurs connectés



Volume

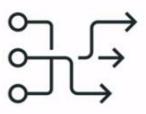


Image : DataBricks

Velocity



Variety



Contraintes à respecter :

- ☐ L'équilibrage de la charge
- ☐ L'optimisation des transfert
- ☐ La tolérance au pannes



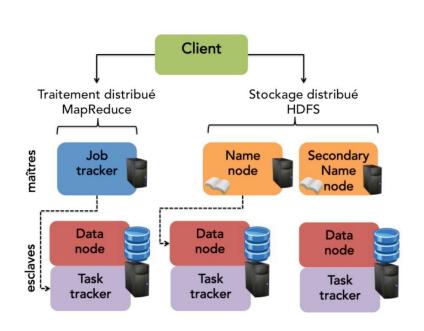
2002, Doug Cutting et Mike Cafarella – Projet Nutch



Projet Hadoop 2006 Fondation Apache 2008



2002, Doug Cutting et Mike Cafarella – Projet Nutch





Projet Hadoop 2006 Fondation Apache 2008

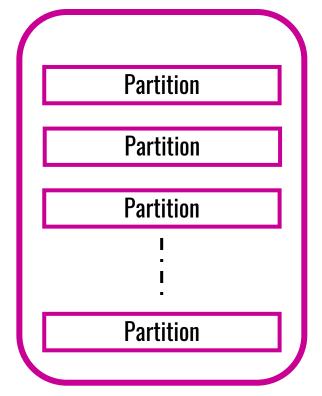
- I. Système HDFS (Hadoop Distributed File System)
 Distribuer / Répliquer / Optimiser
- II. Map Reduce
 Diviser / Résoudre / Réduire
- III. Yarn (Yet Another Resource Negotiator)
 Gestion des ressources / taches



- Elargissement du cadre map reduce
- Ram vs Disque dur
- Resilient Distributed Dataset (RDD)

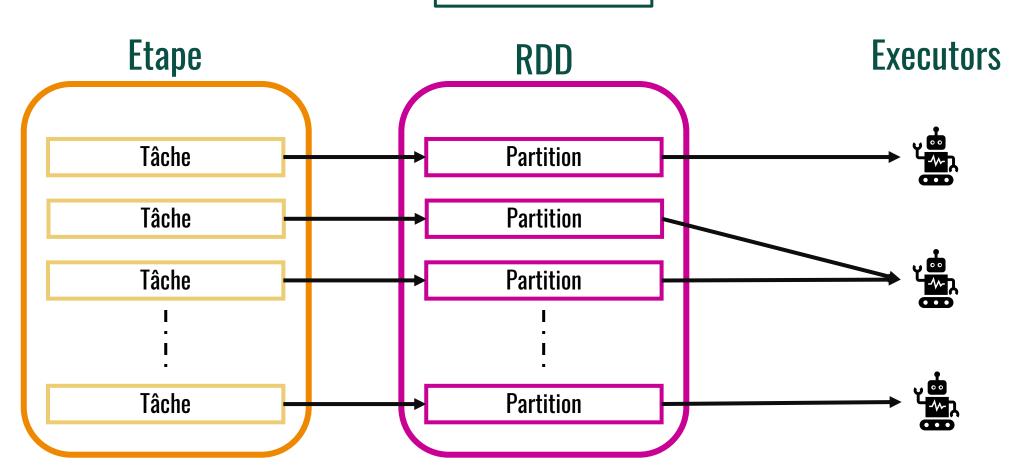


Resilient Distributed Dataset (RDD)





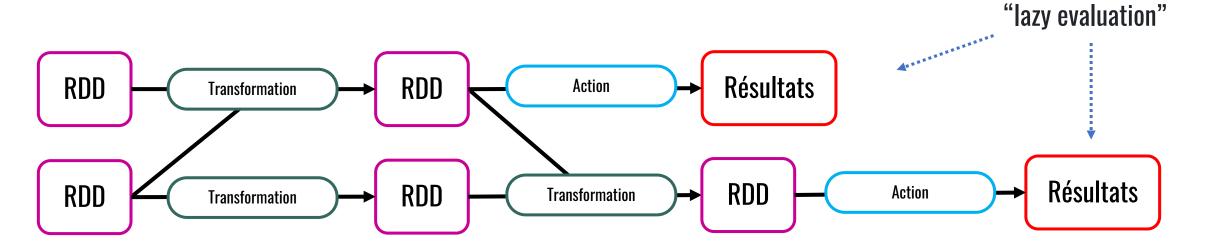
Job Spark





Job Spark

Directed acyclic graph (DAG)











Python

Scala







Partie III – Les solutions AWS

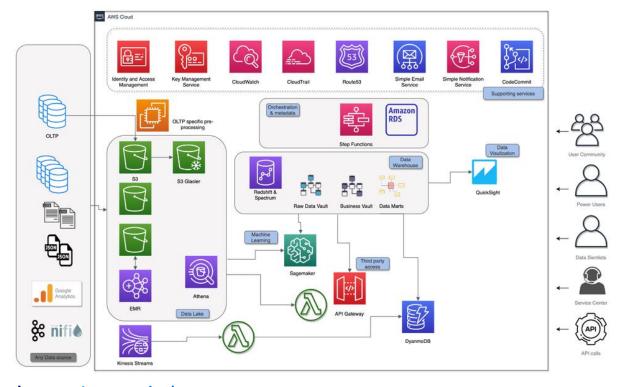
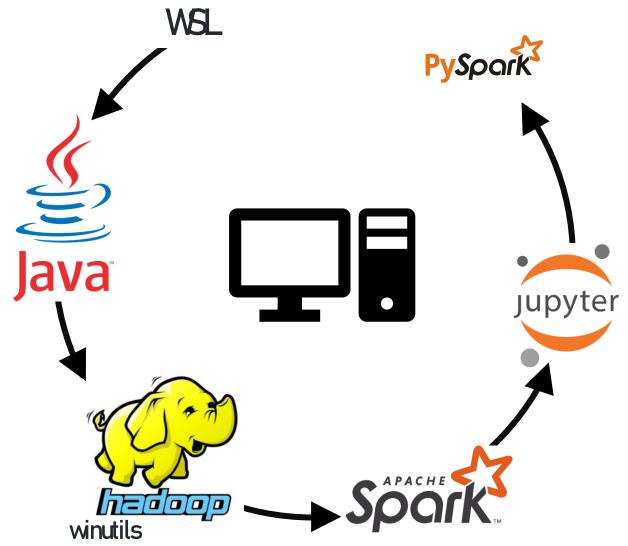


Image : <u>www.tomorrowservices.lu</u>

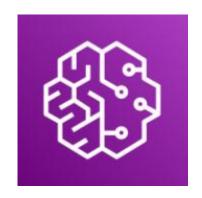


Machine virtuelle en local

- Winutils
- Java
- Hadoop
- Spark
- Jupyter notebook
- Pyspark









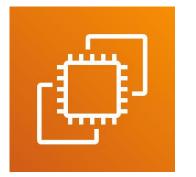






EMR





EC2

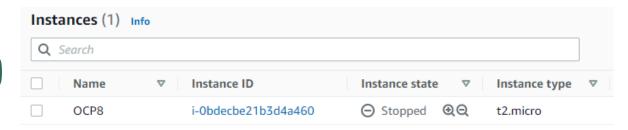




Elastic Compute Cloud (EC2)



- plateforme de calcul / + de 500 instances
- Tout OS (images)
- Bande passante (400 Gbit/s)





- Le moins cher
- Tout est personnalisable
- ❖ Diversité



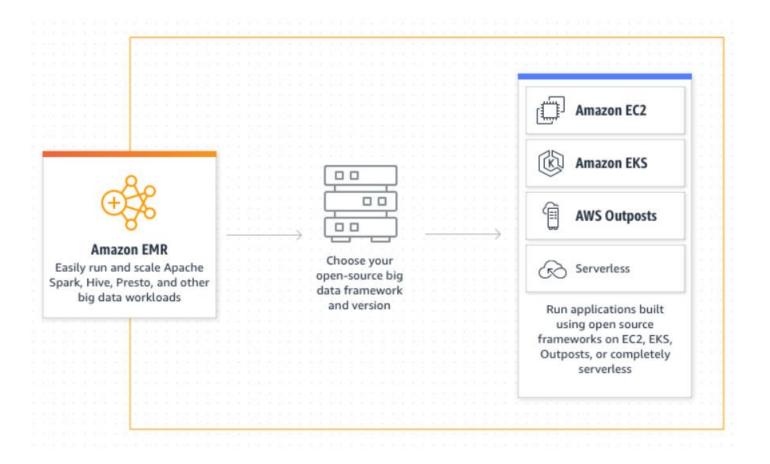
- ❖ Pas de gestion de mise à l'échelle
- (Pas fait pour la Datascience)
 Il faut tout installer



Amazon Elastic MapReduce (EMR)

Plateforme Big Data préconfigurée avec Hadoop

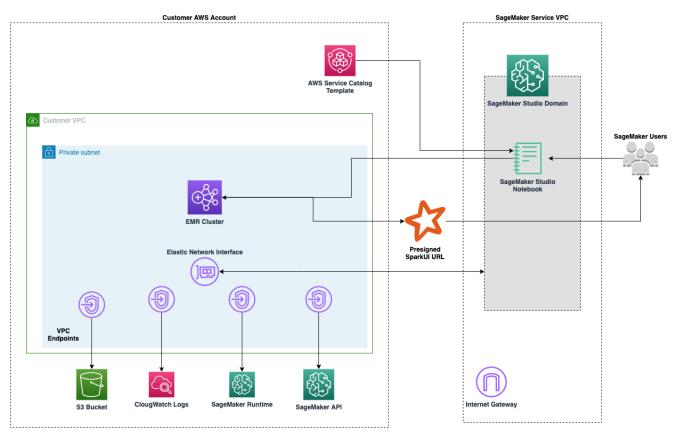
- - préconfiguré
- Pas fait pour la Datasciences

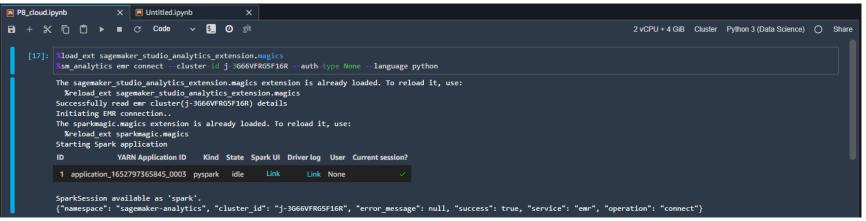




Plateforme Big Data de Datascience

- ♣ Le plus cher
 - ❖ Plus difficile à « gérer »







Partie IV – Le traitement



Image: www.genaris.fr



Le traitement des données

Transfert Learning (projet 6)



Pré-traitement des images

Echelle de gris Histogramme Dimension





Bag of Visual words

CNN features



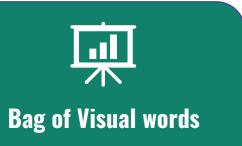


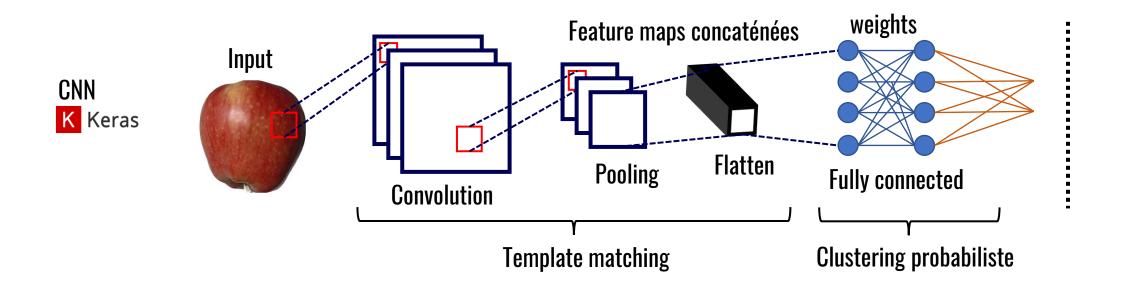
Clustering

K-means



Le traitement des données







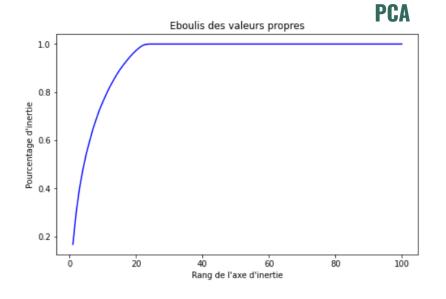
Le traitement des données

Prétraitement des images

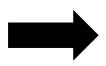


Extraction des features VGG16





Resultats



	path	categ	pca_features_classic	vgg_features_scale	pca_features_vgg
0	5_classes_5_images/Ap	Apple	[-24.096101642763358,	[0.0,0.0,-0.538996857	[3.4186094085814522,1
1	5_classes_5_images/Ap	Apple	[-5.750587401973896,9	[0.0,0.0,-0.538996857	[12.39954595401875,24
2	5_classes_5_images/Ap	Apple	[6.9212516552317,11.5	[0.0,0.0,-0.538996857	[9.836680579559298,18
3	5_classes_5_images/Ap	Apple	[-23.48175022493881,5	[0.0,0.0,-0.538996857	[5.949192329036307,17
4	5_classes_5_images/Ap	Apple	[3.561314541218871,11	[0.0,0.0,-0.538996857	[9.185863884796246,5
5	5_classes_5_images/Av	Avocado	[-22.149714135642597,	[0.0,0.0,-0.538996857	[10.683289615209658,2



Déploiement d'un modèle dans le cloud
 Via EC2 et l'Installations de tous les pré requis
 Via l'utilisation de Sagemaker studio
 data science ≠ data architecture

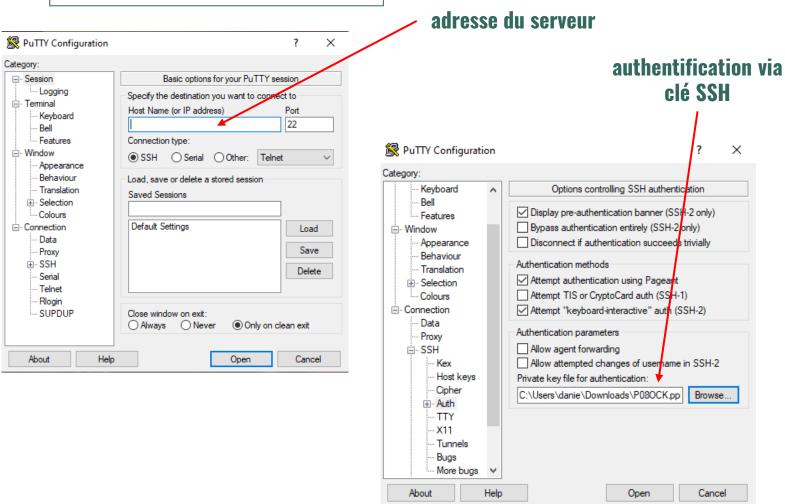
Perspectives

Optimiser l'utilisation de Spark / Debug UI
 Utiliser plus d'images
 Finaliser le modèle avec l'étape de clustering

Login AWS EC2

Connection via PuTTY





Login AWS S3

```
session = boto3.Session(aws access_key_id=access_id, aws_secret_access_key=access_key,)
1 s3 = session.resource("s3")
2 bucket = s3.Bucket("p08oc")
3 obj = bucket.Object(key="5 classes 5 images/Apple/2 100.jpg")
4 response = obj.get()
5 file stream = response[u"Body"]
6 im = Image.open(file_stream)
7 im = im.resize((224, 224))
8 im arr = np.asarray(im)
                                                                                          Bucket and objects not public
                                                        EU (Paris) eu-west-3
                                                                                                                               May 9, 2022, 18:00:10 (UTC+02:00)
p08oc
5_classes_5_images/
                                                          Folder
   Name
                               Name
                                                              Type
                                                                                   Last modified
                                                                                                                                          \nabla
                                                                                                                                                Size
                               2_100.jpg

    △ Apple/

                                                                                   May 9, 2022, 18:00:54 (UTC+02:00)
                                                                                                                                                          4.0 KB
                                                              jpg
                               39_100.jpg
   jpg
                                                                                   May 9, 2022, 18:00:54 (UTC+02:00)
                                                                                                                                                          4.0 KB

□ Banana/
                               4_100.jpg
                                                              jpg
                                                                                   May 9, 2022, 18:00:54 (UTC+02:00)
                                                                                                                                                          4.1 KB
                               70_100.jpg
   Carambula/
                                                                                   May 9, 2022, 18:00:54 (UTC+02:00)
                                                              jpg
                                                                                                                                                          4.5 KB
   □ Cauliflower/
                               73_100.jpg
                                                                                   May 9, 2022, 18:00:55 (UTC+02:00)
                                                              jpg
                                                                                                                                                          5.7 KB
```

Spark 1 spark SparkSession - in-memory SparkContext 1 **from** pyspark.sql **import** SparkSession Spark UI spark = (Version SparkSession.builder.master("local") v3.2.1 Master .getOrCreate() 12 local 13) **AppName** APP P08 1 sc = spark.sparkContext

Création d'une RDD

```
paths = []
for file in bucket.objects.all():
    if file.key.split("/")[0] == "5_classes_5_images":
        paths.append(file.key)

rdd_paths = sc.parallelize(
    paths
    paths
) # Distribute a local Python collection to form an Resilient Distributed Datasets (RDD).
```

RDD to DataFrame

```
1 from pyspark.sql import Row

1 row_rdd_paths = rdd_paths.map(lambda x: Row(x))

1 rddCollect = row_rdd_paths.collect()

1 images_df = spark.createDataFrame(row_rdd_paths, ["path"])

1 images_df.persist(pyspark.StorageLevel.DISK_ONLY)
```

Ajout de la catégorie et l'image sous forme d'array

Création des vecteurs

```
# conversion format vecteur dense
udf_vecto = udf(lambda r: Vectors.dense(r), VectorUDT())
images_df = images_df.withColumn("data", udf_vecto("data"))
```

Standardization

```
# standardisation des données
standardizer = StandardScaler(
    inputCol="data", outputCol="data_scale", withStd=True, withMean=True

    )
model_std = standardizer.fit(images_df)
images_df = model_std.transform(images_df)
```

Extraction de features via VGG16



Merci de votre attention!